

## FILAS DE ESPERA CONTENIDOS

- 1 **Introducción a las filas de espera**
- 2 **Definición y descripción de un sistema de colas**
- 3 **Características de los sistemas de colas**
  - i Patrón de llegada de los clientes
  - ii Patrón de servicio de los servidores
  - iii Disciplina de cola
  - iv Capacidad del sistema
  - v Número de canales del servicio
  - vi Etapas de servicio
- 5 **Funcionamiento de una fila de espera con un Servidor y una fila FIFO**
- 6 **Notación de Kendall**

# 1. Introducción a las filas de espera. Definición

Las **filas de espera** son un fenómeno cotidiano que se manifiesta en diversas situaciones, como en supermercados, bancos, hospitales, servicios telefónicos, procesos industriales, transporte, aplicaciones móviles, uso de redes sociales en lanzamientos de productos, competencia por uso de recursos tecnológicos, etc.. Básicamente, una fila de espera se forma cuando la **demanda de un servicio excede la capacidad del sistema para atenderla de inmediato**. Este fenómeno es de gran importancia porque afecta la eficiencia operativa y la satisfacción del cliente, siendo un factor relevante tanto en el ámbito personal como profesional.

**La TEORÍA DE COLAS, rama de las matemáticas aplicadas, se dedica a estudiar y analizar los sistemas de espera. A través de modelos matemáticos, se busca entender los patrones de llegada de los clientes, los tiempos de servicio y cómo estos elementos interactúan para formar filas.**

Esta teoría no solo permite **predecir** y **minimizar tiempos de espera**, sino que también ayuda a optimizar el uso de recursos, como tiempos del personal, número de empleados, infraestructura, instalaciones, mejorando así la **eficiencia global del sistema**.

La simulación es una herramienta clave en el estudio de las filas de espera porque permite modelar y analizar sistemas complejos en un entorno controlado. A través de la simulación, se pueden probar diferentes escenarios y estrategias sin interferir con el funcionamiento real del sistema. Esto es crucial para identificar cuellos de botella, evaluar el impacto de cambios en la demanda o en la capacidad del servicio, y diseñar sistemas más eficientes y robustos. Además, la simulación facilita la toma de decisiones informadas al proporcionar una comprensión profunda de cómo varían los tiempos de espera y la utilización de los recursos bajo diversas condiciones.

En resumen, el estudio de las **filas de espera** o **colas** mediante **simulación** es esencial para mejorar la **eficiencia y la calidad del servicio en múltiples contextos**, asegurando que los recursos se utilicen de manera **óptima** y que los clientes experimenten **menos tiempo de espera y mayor satisfacción**.

En función de lo mencionado, se comprende que los clientes no quieren esperar y los gestores de los citados servicios no quieren que los clientes esperen. Entonces **¿Por qué hay que esperar?** La respuesta es casi siempre simple, en **algún momento la capacidad de servicio ha sido o es menor que la capacidad demandada**. Esta limitación se puede eliminar invirtiendo en elementos que aumenten la capacidad. En estos casos la pregunta es: ¿Compensa invertir? La teoría de colas intenta responder a estas preguntas.

## Un poco de historia

La **teoría de colas**, también conocida como **teoría de líneas de espera**, tiene su origen en el trabajo del ingeniero danés **Agner Krarup Erlang** a principios del siglo XX. Erlang trabajaba para la **compañía telefónica** danesa y estaba interesado en **optimizar la capacidad de los sistemas telefónicos para manejar las llamadas entrantes**.

Su trabajo se centró en **modelar la capacidad de los centros de llamadas y calcular el tiempo de espera en función de la cantidad de operadores disponibles y el volumen de llamadas recibidas**.

Erlang desarrolló fórmulas matemáticas que permitieron calcular la probabilidad de que una llamada entrante tuviera que esperar para ser atendida, así como el tiempo medio de espera. Sus investigaciones sentaron las bases para la teoría de colas moderna y se publicaron en 1909 en su obra "The Theory of Probabilities and Telephone Conversations".

Con el tiempo, la teoría de colas se expandió más allá de las telecomunicaciones y comenzó a aplicarse en diversas áreas como la informática, la logística, la gestión de servicios, y más, permitiendo optimizar sistemas donde la demanda por un servicio podría exceder la capacidad de atención en ciertos momentos.

### Uso de la simulación en la resolución de modelos de fila de espera

En muchas situaciones, la simulación de sistemas se utiliza para estudiar modelos de filas de espera en lugar de aplicar una resolución analítica debido a varias razones claves:

**Complejidad del Sistema.** Muchos sistemas de colas reales son demasiado complejos para ser modelados analíticamente. Los modelos analíticos generalmente requieren simplificaciones que pueden no capturar todos los aspectos importantes del sistema, mientras que la simulación puede manejar esta complejidad con mayor precisión.

**Flexibilidad y Versatilidad.** La simulación permite probar diferentes configuraciones, políticas y escenarios sin necesidad de cambiar el sistema real. Esto es especialmente útil para optimizar la eficiencia y el rendimiento del sistema de colas.

**Análisis Detallado.** La simulación proporciona un análisis detallado de variables y métricas de rendimiento como tiempos de espera, utilización de recursos, y distribución de llegadas y servicios.

**Evaluación de Variabilidad.** Los sistemas de colas reales a menudo experimentan una gran variabilidad en la demanda y los tiempos de servicio. La simulación permite modelar y evaluar esta variabilidad de manera efectiva, proporcionando una comprensión más realista del desempeño del sistema.

## 2. Definición y descripción de un sistema de colas


Un **SISTEMA DE COLAS** se puede describir como: **clientes** que llegan buscando un **servicio**, **esperan** si este no es inmediato, y **abandonan** el sistema una vez han sido **atendidos**. En algunos casos se puede admitir que los clientes abandonan el sistema si se cansan de esperar.

El término **cliente** se usa con un sentido general y no implica que sea un ser humano, puede significar piezas esperando su turno para ser procesadas o una lista de trabajo esperando para imprimir en una impresora en red, entre múltiples ejemplos que pueden aplicarse para definir el cliente.

Un **MODELO DE FILAS DE ESPERA** o **MODELO DE COLAS** en la **simulación de sistemas** es una **representación matemática** de un **sistema** en el que hay **entidades** (clientes, trabajos, datos, etc.) que llegan para recibir un **servicio**, pero pueden tener que **esperar** debido a que los **recursos** (servidores) están **ocupados**.

Estos modelos permiten analizar y predecir el comportamiento de las colas, incluyendo métricas como el tiempo de espera promedio, la longitud promedio de la cola y la utilización de los servidores.

La siguiente figura ilustra un modelo básico de filas de espera.



Aunque la mayor parte de los sistemas se puedan representar como dicha figura, debe quedar claro que una representación detallada exige definir un número elevado de parámetros y funciones.

### 3. Características de los sistemas de colas

Para comprender cómo funcionan los **modelos de filas** de espera se requiere una descripción detallada de las **características** claves. Estas características incluyen el patrón de llegada de clientes, el patrón de servicio, la disciplina de la cola, la capacidad del sistema, el número de canales y el número de etapas. Cada uno de estos elementos juega un papel crucial en el **comportamiento** y el **rendimiento** del sistema de espera, y su análisis detallado proporciona las bases para diseñar y gestionar eficazmente estos sistemas en diversas aplicaciones prácticas.

#### i. Patrón de llegada de los clientes

En situaciones de colas habituales, la **llegada de las entidades (clientes)** es **estocástica**, es decir la llegada depende de una cierta variable aleatoria, en este caso es necesario conocer la distribución probabilística entre dos llegadas de cliente sucesivas.

En función de lo mencionado, la llegada de clientes se puede clasificar en:

**Determinística.** Los clientes llegan en intervalos de tiempo regulares y predecibles. Por ejemplo, un colectivo que llega a una parada cada 15 minutos.

**Estocástica.** En la mayoría de los sistemas reales, las llegadas son aleatorias y pueden modelarse utilizando procesos probabilísticos. El proceso de Poisson es una de las formas más comunes de modelar llegadas aleatorias, donde los clientes llegan a intervalos de tiempo independientes y exponencialmente distribuidos. La tasa de llegada ( $\lambda$ ) indica el promedio de llegadas por unidad de tiempo.

Además habría que tener en cuenta si los clientes llegan independiente o simultáneamente. En este segundo caso (es decir, si llegan **lotes**) habría que definir la distribución probabilística de éstos.

También es posible que los clientes sean “impacientes”. Es decir, que lleguen a la cola y si es demasiado larga se vayan, o que tras esperar mucho rato en la cola decidan **abandonar**.

Por último es posible que el patrón de llegada varíe con el tiempo. Si se mantiene constante se llama **estacionario**, y si varía con las horas del día es **no-estacionario**.

## ii. Patrón de servicio de los servidores

El **patrón de servicio** describe **cómo los clientes son atendidos** una vez que ingresan al sistema. Esto incluye el tiempo que cada cliente pasa siendo atendido. Al igual que las llegadas, los servicios pueden ser:

**Determinísticos.** El tiempo de servicio es constante para todos los clientes. Por ejemplo, una máquina que toma exactamente 2 minutos para procesar cada pieza.

**Estocásticos.** El tiempo de servicio varía y se puede modelar usando diferentes distribuciones probabilísticas, como la distribución exponencial, normal, entre otras. La tasa de servicio ( $\mu$ ) es un parámetro clave que define el número promedio de clientes que un servidor puede atender por unidad de tiempo.

Los servidores pueden tener un tiempo de servicio variable, en cuyo caso hay que asociarle, para definirlo, una función de probabilidad. También pueden atender en lotes o de modo individual.

El tiempo de servicio también puede variar con el número de clientes en la cola, trabajando más rápido o más lento, y en este caso se llama patrones de servicio dependientes. Al igual que el patrón de llegadas el patrón de servicio puede ser no-estacionario, variando con el tiempo transcurrido.

## iii. Disciplina de la cola

La **disciplina de la cola** se refiere a las **reglas que determinan el orden en que los clientes son atendidos**.

La disciplina de cola es la **manera en que los clientes se ordenan** en el momento de ser servidos de entre los de la cola.

Las disciplinas más comunes son:

**FIFO (First In, First Out).** Los clientes son atendidos en el orden en que llegaron. Este es el tipo más común de disciplina y se utiliza en muchos sistemas, como las líneas de espera en supermercados.

**LIFO (Last In, First Out).** El último cliente en llegar es el primero en ser atendido. Este tipo de disciplina es menos común y puede encontrarse en ciertos contextos de almacenamiento o procesamiento de datos.

**SIRO (Service In Random Order).** Los clientes son atendidos en un orden aleatorio, sin tener en cuenta su orden de llegada.

**Prioridades.** Algunos clientes pueden tener prioridad sobre otros, lo que significa que se les atiende antes independientemente de cuándo llegaron. Esto puede basarse en la urgencia del servicio, el tipo de cliente (por ejemplo, clientes VIP), o cualquier otra política definida por el sistema.

Cuando se piensa en colas se admite que la disciplina de cola normal es **FIFO** (atender primero a quien llegó primero) Sin embargo en muchas colas es habitual el uso de la disciplina **LIFO** (atender primero al último).

Es posible encontrar reglas de secuencia con **prioridades**, por ejemplo secuenciar primero las tareas con menor duración, pacientes que ingresan a un servicio médico y se atienden en función de la gravedad de su condición médica, procesos de embarques de pasajeros en aviones, soporte técnico y atención a clientes por urgencia de problemas reclamados, tipos de clientes, etc.. En cualquier caso dos son las situaciones generales en las que trabajar:

**Preemptive** con derecho preferente. Si un cliente llega a la cola con una orden de prioridad superior al cliente que está siendo atendido, este se retira dando paso al más importante. Dos nuevos subcasos aparecen:

- el cliente retirado ha de volver a empezar.
- el cliente retorna donde se había quedado.

**No-preemptive.** El cliente con mayor prioridad espera a que acabe el que está siendo atendido.

#### iv. Capacidad del sistema

La capacidad del sistema se refiere al **número máximo de clientes que pueden estar presentes en el sistema simultáneamente**, incluyendo tanto los que están siendo atendidos como los que están esperando. La capacidad puede ser:

**Limitada.** Solo se permite un número específico de clientes en el sistema a la vez. Una vez alcanzada esta capacidad, los clientes adicionales no pueden entrar al sistema hasta que algunos hayan sido atendidos y se haya liberado espacio. Un ejemplo sería un estacionamiento con un número fijo de espacios.


**Ilimitada.** No hay restricción en el número de clientes que el sistema puede manejar simultáneamente. Los clientes pueden seguir llegando y esperar en la cola independientemente del número de clientes ya presentes.

#### v. Número de canales del servicio

El número de canales en un sistema de colas se refiere a los **servidores disponibles para atender a los clientes simultáneamente**. La configuración de cómo se forman las colas (una cola para múltiples servidores versus una cola por cada servidor) afecta significativamente la eficiencia y la percepción del sistema de espera. Elegir la configuración adecuada depende de factores como el espacio físico disponible, la naturaleza del servicio y las expectativas de los clientes.

Las configuraciones principales para este tipo de sistema son :

**Una cola para múltiples servidores (single queue, multiple servers).**



En este enfoque, todos los clientes forman una única cola y los servidores atienden a los clientes de esa cola a medida que están disponibles. Esta configuración es común en bancos, supermercados y aeropuertos, donde una sola fila de clientes se divide entre varios cajeros o agentes disponibles.

**Ventajas:**

Reducción del tiempo promedio de espera, ya que el cliente es atendido por el primer servidor disponible.

Percepción de equidad, ya que todos los clientes tienen la misma oportunidad de ser atendidos en el orden de llegada.

### Desventajas:

Puede requerir más espacio físico para acomodar una única cola larga.

### Una cola por cada servidor (multiple queues, multiple servers).



En este enfoque, cada servidor tiene su propia cola. Los clientes eligen una cola específica y esperan ser atendidos por el servidor asignado a esa cola. Este sistema se observa en muchas tiendas minoristas, donde cada caja registradora tiene su propia fila de clientes.

### Ventajas:

Menos espacio físico necesario para cada cola individual.


Puede generar una percepción de competencia, donde los clientes intentan seleccionar la cola que parece más rápida.

### Desventajas:


Puede resultar en una desigualdad en los tiempos de espera si una cola se mueve más rápido que las demás.

Los clientes pueden experimentar frustración si ven que otras colas avanzan más rápido


### Modelo de una sola cola con un único servidor



### Modelo de una sola cola con dos servidores



Por todo lo mencionado, un sistema de fila de espera puede tener múltiples representaciones. Por ejemplo:




## vi. Etapas del servicio

El número de etapas se refiere al **número de fases o procesos que un cliente debe atravesar para completar su servicio**. Los sistemas pueden ser:

**De una sola etapa (single-stage).** El cliente completa su servicio en una única interacción. Por ejemplo, pagar en una caja registradora.

**De múltiples etapas (multi-stage).** El cliente debe pasar por varias etapas o estaciones para completar el servicio. Un ejemplo de esto es el proceso de chequeo de equipaje en un aeropuerto, donde el cliente debe pasar por varias etapas como el registro, la revisión de seguridad y la entrega del equipaje.



## 4. Funcionamiento de una fila de espera con un Servidor y una fila FIFO

Uno de los modelos más básicos y ampliamente utilizados es el sistema de fila de espera con un solo servidor y una disciplina de cola FIFO (First In, First Out). El siguiente ejemplo tiene por objetivo entender el comportamiento de sistemas de espera, para lo cual se utiliza la teoría de colas.

El análisis se centra en un negocio donde los clientes llegan de uno en uno. Si el servidor está libre, el cliente es atendido de inmediato; de lo contrario, debe esperar hasta que el cliente actual termine su servicio y se retire del sistema. La organización de la cola sigue una disciplina FIFO (First In, First Out) y no hay límites en el número de clientes que pueden esperar en el sistema. El análisis considera varios factores claves como el tiempo de llegada de cada cliente, el tiempo de servicio, el tiempo de espera del cliente y el tiempo de ocio del servidor. El ejemplo analiza la llegada y atención de seis clientes. El momento de llegada de cada cliente y tiempo de servicio es un valor cualquier constante a los efectos de desarrollar un modelo base.

| Cliente | Momento de llegada | Tiempo de Servicio | Inicio del servicio | Instante que abandona el sistema | Tiempo ocio servidor | Tiempo Espera cliente |
|---------|--------------------|--------------------|---------------------|----------------------------------|----------------------|-----------------------|
| 1       | 0                  | 3                  | 0                   | 3                                | 0                    | 0                     |
| 2       | 5                  | 4                  | 5                   | 9                                | 2                    | 0                     |
| 3       | 7                  | 5                  | 9                   | 14                               | 0                    | 2                     |
| 4       | 14                 | 7                  | 14                  | 21                               | 0                    | 0                     |
| 5       | 23                 | 7                  | 23                  | 30                               | 2                    | 0                     |
| 6       | 25                 | 5                  | 30                  | 35                               | 0                    | 5                     |
|         |                    |                    |                     |                                  | 4                    | 7                     |

Tiempo total de funcionamiento del sistema: 35


Tiempo total de ocio del servidor: 4

Porcentaje Promedio de tiempo de ocio del servidor 11,43%

Tiempo total de espera del cliente: 7

Porcentaje Promedio de tiempo de espera del cliente 20,00%

#### AVANCE DEL TIEMPO



## 5. Notación de Kendall

La notación Kendall es una **forma estándar de describir y clasificar los modelos de filas de espera**. Introducida por David G. Kendall en 1953, esta notación utiliza una secuencia de letras y números para caracterizar los aspectos clave de un sistema de colas.

**La notación KENDALL es una herramienta poderosa y versátil para describir los diferentes modelos de colas en términos claros y concisos. Permite identificar rápidamente las características y suposiciones de un modelo de fila de espera, facilitando así el análisis y la optimización de los sistemas de espera.**

La **notación básica** es de la forma **A/B/s/K/N/D**, donde cada símbolo representa una característica específica del sistema de colas. A continuación se detalla el significado de cada componente de la notación Kendall:

### A - Distribución de tiempos entre llegadas:

Describe la distribución de los intervalos de tiempo entre llegadas de clientes. Las situaciones más comunes son :

M: Llegadas según un proceso de Poisson (intervalos de tiempo exponenciales).

D: Llegadas determinísticas (intervalos de tiempo constantes).

G: Distribución general (cualquier distribución).

### **B - Distribución de tiempos de servicio:**

Describe la distribución del tiempo de servicio de cada cliente. Las situaciones más comunes son :

M: Tiempos de servicio exponenciales.

D: Tiempos de servicio determinísticos (constantes).

G: Distribución general de tiempos de servicio.

### **s - Número de servidores:**

Indica el número de servidores disponibles en paralelo para atender a los clientes.

### **K - Capacidad del sistema:**

Define el número máximo de clientes que pueden estar en el sistema, tanto esperando como siendo atendidos. Si no hay límite, se usa  $\infty$  (infinito).

### **N - Tamaño de la población de clientes:**

Número total de clientes potenciales que pueden llegar al sistema. Si la población es infinita, se usa  $\infty$ .

### **D - Disciplina de la cola:**

Describe la regla que determina el orden en que los clientes son atendidos. Comúnmente omitido si se asume FIFO. Algunos ejemplos:

FIFO: First In, First Out.

LIFO: Last In, First Out.

SIRO: Service In Random Order.

PR: Prioridad.

Se presentan tres ejemplos que describen Notación Kendall para describir el comportamiento y la caracterización de un modelo de filas de espera:

### **M/M/1:**

Llegadas según un proceso de Poisson.

Tiempos de servicio exponenciales.

Un solo servidor.

Capacidad infinita.

Población infinita.

Disciplina FIFO (implícita).

### **M/D/3:**

Llegadas según un proceso de Poisson.

Tiempos de servicio determinísticos.

Tres servidores.

Capacidad infinita.

Población infinita.

Disciplina FIFO (implícita).

### **G/G/2/K:**

Distribución general de tiempos entre llegadas.

Distribución general de tiempos de servicio.

Dos servidores.

Capacidad del sistema limitada a K clientes.

Población infinita.

Disciplina FIFO (implícita).